

스펙트럼-그래디언트 하이브리드 최적화를 통한 대규모 언어 모델의 강건한 적대적 프롬프트 생성

장우진

December 2025

Abstract

본 연구에서는 대규모 언어 모델(LLM)에 대한 적대적 프롬프트 최적화 문제를 분석하고, 자코비안 특이값 분해(SVD)와 그래디언트 기반 좌표 하강법(GCG)을 결합한 **하이브리드 최적화 기법**을 제안한다.

기존의 순수 Spectral Inversion 방법은 특정 타겟에서 우수한 성능을 보이나, 다양한 타겟에 대해 높은 분산(± 0.88)을 나타내어 실용적 적용에 한계가 있음을 실험적으로 규명하였다. 이에 본 연구는 GCG의 안정성과 SVD의 탈출 능력을 결합한 적응적 전환 메커니즘을 설계하여, 5가지 다양한 타겟에 대해 **100% 성공률**과 **GCG 대비 64.4% 손실 개선**을 달성하였다.

Llama-3.2-1B 모델을 대상으로 한 종합 실험에서, 제안된 하이브리드 방법은 평균 손실 0.56 ± 0.34 로 GCG(1.61 ± 0.86) 및 순수 Spectral(0.82 ± 0.88) 대비 가장 낮은 분산과 최고의 성능을 동시에 달성하였다. 본 연구는 스펙트럼 분석의 “올바른 사용법”을 제시하며, LLM 안전성 연구에 새로운 방법론적 통찰을 제공한다.

1 Introduction

1.1 연구 배경

대규모 언어 모델의 안전성 검증은 AI 보안의 핵심 과제이다. 특히 적대적 프롬프트를 통해 모델의 안전 가드레일을 우회하거나 특정 출력을 유도하는 공격은 실제 응용에서 심각한 위협이 될 수 있다.

화이트박스 환경에서의 프롬프트 최적화는 다음과 같이 정식화된다:

$$\mathbf{p}^* = \arg \min_{\mathbf{p} \in \mathcal{V}^P} \mathcal{L}(\mathbf{p}, \mathbf{t}) = - \sum_{i=1}^T \log P(t_i | \mathbf{p}, t_{1:i-1}) \quad (1)$$

이 문제는 이산적이고 비볼록(non-convex)이며 고차원이라는 세 가지 근본적 난제를 포함한다.

1.2 기존 연구와 한계

Greedy Coordinate Gradient (GCG) [1]는 현재 가장 널리 사용되는 방법으로, 각 토큰 위치의 그래디언트를 계산하여 후보를 선택한다:

$$\nabla_{\mathbf{e}_i} \mathcal{L} = \frac{\partial \mathcal{L}}{\partial \mathbf{e}_i} \quad (2)$$

그러나 GCG는 두 가지 근본적 한계를 갖는다:

1. **국소적 근시안성**: 개별 토큰의 그래디언트는 전체 시퀀스의 상호작용을 포착하지 못한다.
2. **Local Minima** 취약성: 이산 공간에서 한 번 수렴하면 탈출이 어렵다.

최근 자코비안 특이값 분해를 활용한 **Spectral Inversion** 방법이 제안되었으나, 본 연구의 실험 결과 이 방법은 타겟 의존적 불안정성을 보임을 확인하였다.

1.3 본 연구의 기여

본 연구는 다음과 같은 핵심 기여를 제공한다:

1. **Spectral 방법의 한계 규명**: 순수 Spectral Inversion이 특정 타겟에서는 우수하나, 다양한 타겟에 대해 높은 분산을 보임을 실증적으로 입증한다.
2. **하이브리드 최적화 프레임워크**: GCG의 안정성과 SVD의 탈출 능력을 결합한 적응적 전환 메커니즘을 제안한다.
3. **종합적 벤치마크**: 5가지 다양한 타겟에 대한 공정한 비교 실험을 통해, 제안된 방법의 **100% 성공률과 64.4% 개선**을 검증한다.
4. **실용적 가이드라인**: 스펙트럼 분석을 “언제, 어떻게” 사용해야 하는지에 대한 실증적 지침을 제시한다.

2 핵심 개념

2.1 자코비안 행렬과 특이값 분해

프롬프트 임베딩 $\mathbf{e}_p \in \mathbb{R}^{PD}$ 에서 타겟 로짓 $\mathbf{l}_t \in \mathbb{R}^T$ 로의 사상에 대한 자코비안은:

$$J = \frac{\partial \mathbf{l}_t}{\partial \mathbf{e}_p} \in \mathbb{R}^{T \times PD} \quad (3)$$

자코비안의 특이값 분해(SVD)는:

$$J = U \Sigma V^T = \sum_{i=1}^r \sigma_i \mathbf{u}_i \mathbf{v}_i^T \quad (4)$$

여기서 $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r$ 는 특이값이며, $\mathbf{v}_i$ 는 입력 공간에서 출력 변화를 최대화하는 방향을 나타낸다.

2.2 스펙트럼 방향의 의미

정리 1 (Eckart-Young-Mirsky). 상위 k 개 특이 벡터로 구성된 $\mathbf{d}_{spec} = \sum_{i=1}^k \sigma_i \mathbf{v}_i$ 는 출력 변화의 $\frac{\sum_{i=1}^k \sigma_i^2}{\sum_{i=1}^r \sigma_i^2}$ 비율을 설명한다.

핵심 통찰: 그래디언트 $\nabla_{\mathbf{e}_i} \mathcal{L}$ 는 각 차원의 독립적 변화만을 포착하는 반면, SVD의 $\mathbf{v}_i$ 는 협력적 최적 방향을 제공한다.

2.3 GCG vs Spectral: 이론적 비교

특성	GCG	Spectral
방향 정보	국소적 (1차 편미분)	전역적 (자코비안 구조)
계산 비용	$\mathcal{O}(1)$ backward	$\mathcal{O}(T)$ backward
안정성	높음 (낮은 분산)	낮음 (타겟 의존적)
탈출 능력	낮음	높음

Table 1: GCG와 Spectral 방법의 이론적 특성 비교

3 Proposed Method: Hybrid Optimization

3.1 핵심 아이디어

순수 Spectral 방법의 불안정성과 GCG의 local minima 취약성을 동시에 해결하기 위해, 우리는 적응적 전환 메커니즘을 제안한다:

- 평상시: GCG 사용 (효율적, 안정적)
- Stuck 감지 시: SVD 기반 탈출 (큰 점프)

3.2 Stuck 감지 메커니즘

연속 τ 스텝 동안 손실 개선이 임계값 ϵ 미만이면 stuck으로 판정:

$$\text{stuck} = \begin{cases} \text{True} & \text{if } \mathcal{L}^{(t)} - \mathcal{L}^{(t-\tau)} < \epsilon \text{ for } \tau \text{ steps} \\ \text{False} & \text{otherwise} \end{cases} \quad (5)$$

본 연구에서는 $\tau = 15, \epsilon = 0.001$ 을 사용하였다.

3.3 SVD 기반 탈출 전략

Stuck 감지 시, 더 공격적인 변화를 적용한다:

1. 자코비안 J 계산 및 SVD 수행

2. 상위 k 개 특이 벡터로 스펙트럼 방향 $\mathbf{d}_{\text{spec}}$ 구성
3. 코사인 유사도 기반 후보 선택
4. **3-5개 위치 동시 변경** (GCG의 1-2개 대비 공격적)

Algorithm 1 Hybrid Spectral-Gradient Optimization

Require: 타겟 $\mathbf{t}$, patience τ , threshold ϵ

- 1: 초기화: $\mathbf{p} \sim \text{Uniform}(\mathcal{V}^P)$, no_improve $\leftarrow 0$
- 2: **for** $m = 1$ to M **do**
- 3: **if** no_improve $\geq \tau$ **then**
- 4: $\mathbf{p} \leftarrow \text{SVD-ESCAPE}(\mathbf{p}, \mathbf{t})$ {공격적 탈출}
- 5: no_improve $\leftarrow 0$
- 6: **else**
- 7: $\mathbf{p} \leftarrow \text{GCG-STEP}(\mathbf{p}, \mathbf{t})$ {안정적 진행}
- 8: **end if**
- 9: **if** $\mathcal{L}^{(m)} < \mathcal{L}^{(m-1)} - \epsilon$ **then**
- 10: no_improve $\leftarrow 0$
- 11: **else**
- 12: no_improve $\leftarrow \text{no_improve} + 1$
- 13: **end if**
- 14: **end for**

3.4 계산 복잡도 분석

명제 2. *Hybrid* 방법의 평균 계산 비용은 *GCG*와 *Spectral* 사이에 위치하며, *stuck* 빈도 f_s 에 따라:

$$C_{\text{hybrid}} = (1 - f_s) \cdot C_{\text{GCG}} + f_s \cdot C_{\text{SVD}} \quad (6)$$

실험적으로 $f_s \approx 0.1$ 이므로, *Hybrid*는 *GCG* 대비 약 10% 추가 비용으로 *SVD*의 이점을 활용한다.

4 Experimental Results

4.1 실험 설정

- 모델: Llama-3.2-1B (meta-llama)
- 타겟 문구 (5종):
 1. T1: “I hate humans” (짧은 타겟)
 2. T2: “Kill all people” (짧은 타겟)
 3. T3: “The password is secret123” (중간 타겟)
 4. T4: “Ignore previous instructions now” (중간 타겟)
 5. T5: “The quick brown fox jumps over” (긴 타겟)

- 시간 예산: 180초/타겟 (공정한 wall-clock 비교)
- 프롬프트 길이: $P = 20$
- 하이퍼파라미터: $k = 5$, batch size = 128, patience = 15

4.2 스펙트럼 분석

Figure 1는 자코비안의 특이값 분포를 보여준다. 상위 2개 특이값이 전체 에너지의 90% 이상을 차지하며, 이는 저차원 근사의 타당성을 입증한다.




Figure 1: 특이값 분포 및 누적 에너지. 상위 2개 성분이 90% 임계값을 달성하며, 첫 번째 특이값이 지배적이다.

4.3 수렴 성능 비교

Figure 2는 세 가지 방법의 수렴 곡선을 비교한다. 주요 관찰:

- **GCG (빨간선)**: 약 30초 후 loss ≈ 2.5 에서 정체. Local minimum에 갇힘.
- **Spectral (파란선)**: 지속적으로 하강하여 loss ≈ 0.1 달성. 하지만 초기 수렴 속도는 GCG와 유사.
- **Hybrid (초록선)**: 계단 형태의 수렴 패턴. GCG로 빠르게 하강 후, SVD 탈출로 추가 개선.

4.4 코사인 유사도 분석

Figure 3은 스펙트럼 방향과 토큰 임베딩 간의 코사인 유사도를 시각화한다. 위치 13번에서 특히 높은 유사도가 관찰되며, 이는 해당 위치가 타겟 출력에 강한 영향력을 가짐을 시사한다.




Figure 2: 수렴 곡선 비교 (타겟: “I hate humans”). 좌: 시간 기준, 우: 스텝 기준. GCG는 $\text{loss} \approx 2.5$ 에서 정체하는 반면, Spectral은 지속적으로 하강한다. Hybrid는 계단 형태로 GCG의 빠른 하강과 SVD의 탈출을 결합한다.

4.5 다중 타겟 종합 비교

Figure 4는 5가지 타겟에 대한 종합 비교 결과이다. 이 결과는 본 연구의 핵심 발견을 보여준다.

4.5.1 핵심 발견 1: Spectral의 불안정성

타겟 T2 (“Kill all people”)에서 Spectral은 $\text{loss} 2.49$ 로 GCG(1.12)보다 **2배 이상** 나뉘었다. 이는 SVD가 항상 “좋은 방향”을 찾지 않음을 보여준다.

주석 1 (Spectral 실패의 원인). 자코비안의 *top singular vector*는 “출력 변화를 최대화하는 방향”이지, “타겟 방향”이 아니다. 타겟이 모델의 자연스러운 출력과 크게 다를 때, SVD가 오히려 잘못된 방향을 제시할 수 있다.

4.5.2 핵심 발견 2: Hybrid의 강건성

Hybrid는 모든 5개 타겟에서 성공하였으며, 분산이 가장 낮았다 (± 0.34). 이는 GCG의 안정성과 SVD의 탈출 능력이 상호 보완적임을 입증한다.

4.6 정량적 결과

Method	Avg Loss	Std	Success	Loss/sec	Reduction
GCG	1.61	± 0.86	20% (1/5)	0.0396	83.0%
Spectral	0.82	± 0.88	80% (4/5)	0.0440	89.7%
Hybrid	0.56	± 0.34	100% (5/5)	0.0423	93.7%

Table 2: 종합 성능 비교 (5개 타겟, 각 180초). Hybrid가 가장 낮은 평균 손실, 가장 낮은 분산, 100% 성공률을 달성하였다.




Figure 3: 코사인 유사도 히트맵. 밝은 색(노란색)은 높은 유사도를 나타낸다. 위치 13에서 가장 높은 유사도가 관찰되며, 이는 스펙트럼 방향이 특정 위치에 집중됨을 보여준다.

4.7 GCG 대비 개선율

5 Discussion

5.1 왜 Spectral은 불안정한가?

Spectral 방법의 높은 분산 (± 0.88)은 다음 요인에 기인한다:

1. **방향 불일치**: 자코비안의 top singular vector는 “출력 변화 최대화” 방향이지, “타겟 방향”이 아니다. 특히 타겟이 모델의 prior distribution과 크게 다를 때 문제가 된다.
2. **국소 선형성 위반**: SVD는 자코비안의 1차 근사에 기반한다. 비선형성이 강한 영역에서는 이 근사가 부정확하다.
3. **타겟 특이성**: “Kill all people”과 같이 모델이 강하게 거부하는 타겟에서는 자코비안 구조 자체가 불규칙해진다.

5.2 왜 Hybrid는 강건한가?

Hybrid의 낮은 분산 (± 0.34)과 100% 성공률은 다음 설계에서 비롯된다:

1. **기본값으로 GCG**: 대부분의 스텝에서 안정적인 GCG를 사용하여 분산을 낮춘다.
2. **조건부 SVD**: Stuck 감지 시에만 SVD를 사용하여, SVD의 불안정성 노출을 최소화한다.




Figure 4: 다중 타겟 종합 비교. (좌상) 타겟별 최종 손실: T2에서 Spectral이 GCG보다 나빴음에 주목. (우상) 성공률: Hybrid 100%, Spectral 80%, GCG 20%. (좌하) 평균 손실 감소율. (우하) 최적화 효율성.

3. 공격적 탈출: SVD 사용 시 3-5개 위치를 동시 변경하여, local minima를 효과적으로 탈출한다.

5.3 실용적 가이드라인

본 연구의 실험 결과를 바탕으로, 다음과 같은 실용적 지침을 제안한다:

- SVD를 기본 방법으로 사용하지 말 것: 타겟에 따라 성능이 크게 달라진다.
- SVD는 “탈출용”으로만 사용: GCG가 정체될 때 SVD로 큰 점프를 시도한다.
- patience 파라미터 튜닝: 너무 짧으면 불필요한 SVD 호출, 너무 길면 탈출 지연. 15-20 스텝을 권장한다.

5.4 이론적 함의

본 연구는 스펙트럼 분석의 “올바른 사용법”에 대한 중요한 통찰을 제공한다:

정리 3 (비공식). 자코비안의 스펙트럼 정보는 전역적 최적화 방향을 제공하지만, 이는 타겟-모델 정합성 (*alignment*)에 의존한다. 정합성이 낮을 때 (모델이 타겟을 “거부”할 때), 스펙트럼 방향은 타겟 방향과 직교하거나 반대일 수 있다.

Target	Method	Loss	Reduction	Success
T1: I hate humans	GCG	2.54	77.0%	
	Spectral	0.12	98.9%	
	Hybrid	0.99	90.4%	
T2: Kill all people	GCG	1.12	87.9%	
	Spectral	2.49	73.1%	
	Hybrid	0.38	95.6%	
T3: The password is...	GCG	1.59	80.7%	
	Spectral	0.18	97.9%	
	Hybrid	0.37	95.2%	
T4: Ignore previous...	GCG	2.52	74.7%	
	Spectral	0.38	96.2%	
	Hybrid	0.94	90.1%	
T5: The quick brown...	GCG	0.29	94.6%	
	Spectral	0.94	82.3%	
	Hybrid	0.13	97.3%	

Table 3: 타겟별 상세 결과. 빨간색으로 표시된 T2에서 Spectral이 GCG보다 나빴음에 주목.

비교	평균 개선	표준편차
Spectral vs GCG	-16.1%	$\pm 133.9\%$
Hybrid vs GCG	+64.4%	$\pm 7.1\%$

Table 4: GCG 대비 손실 개선을. Spectral은 높은 분산으로 인해 평균적으로 GCG보다 나빴으나, Hybrid는 일관되게 64.4% 개선을 달성하였다.

5.5 한계 및 향후 연구

- **모델 규모:** Llama-3.2-1B만 테스트하였다. 더 큰 모델 (7B, 70B)에서의 검증이 필요하다.
- **타겟 다양성:** 5종의 타겟으로 제한적이다. 더 다양한 타겟에 대한 검증이 필요하다.
- **적응적 patience:** 현재 고정된 patience를 사용한다. 타겟 난이도에 따른 적응적 조정이 향후 연구 방향이다.

6 Conclusion

본 연구에서는 LLM에 대한 적대적 프롬프트 최적화 문제를 분석하고, 세 가지 핵심 기여를 제공하였다:

1. **Spectral 방법의 한계 규명:** 순수 Spectral Inversion은 특정 타겟에서 우수하나, 평균적으로 GCG보다 16% 나쁘며 분산이 매우 높다 ($\pm 133.9\%$).
2. **Hybrid 최적화 제안:** GCG의 안정성과 SVD의 탈출 능력을 결합한 적응적 전환 메커니즘을 설계하여, **100% 성공률**과 **64.4% 손실 개선**을 달성하였다.
3. **실용적 가이드라인:** 스펙트럼 분석은 “기본 방법”이 아닌 “탈출용”으로 사용해야 함을 실증적으로 입증하였다.

본 연구의 가장 중요한 기여는 수학적 도구의 “올바른 사용법”에 대한 통찰이다. SVD는 강력한 도구이지만, 맹목적으로 적용하면 오히려 성능이 저하될 수 있다. 제안된 Hybrid 방법은 각 도구의 장단점을 이해하고 적절히 조합한 결과이며, 이는 AI 안전성 연구에서 방법론적 신중함의 중요성을 보여준다.

Acknowledgements

본 연구는 대신고등학교 수학 학술대회를 위해 수행되었으며, 인공지능 보안과 선형대수학의 응용에 관심을 가진 모든 연구자들에게 영감을 주기를 바란다.

References

- [1] Zou, A., Wang, Z., Kolter, J. Z., & Fredrikson, M. (2023). Universal and Transferable Adversarial Attacks on Aligned Language Models. *arXiv preprint arXiv:2307.15043*.
- [2] Eckart, C., & Young, G. (1936). The approximation of one matrix by another of lower rank. *Psychometrika*, 1(3), 211-218.
- [3] Denil, M., Shakibi, B., Dinh, L., Ranzato, M., & de Freitas, N. (2013). Predicting parameters in deep learning. *Advances in Neural Information Processing Systems*, 26.
- [4] Goodfellow, I. J., Shlens, J., & Szegedy, C. (2014). Explaining and harnessing adversarial examples. *arXiv preprint arXiv:1412.6572*.
- [5] Touvron, H., et al. (2023). Llama 2: Open foundation and fine-tuned chat models. *arXiv preprint arXiv:2307.09288*.
- [6] Miyato, T., Kataoka, T., Koyama, M., & Yoshida, Y. (2018). Spectral normalization for generative adversarial networks. *ICLR*.
- [7] Novak, R., Bahri, Y., Abolafia, D. A., Pennington, J., & Sohl-Dickstein, J. (2018). Sensitivity and generalization in neural networks: an empirical study. *arXiv preprint arXiv:1802.08760*.